UNIVERSIDADE REGIONAL DE BLUMENAU
CENTRO DE CIÊNCIAS EXATAS E NATURAIS
CURSO DE CIÊNCIA DA COMPUTAÇÃO
Processamento de Linguagem Natural — 2026/2

Trabalho da Unidade 3

Librarian AI: gênero literário de livros em PDF — representações textuais e tarefas de PLN

Equipe: Pedro Rafael, Leonardo Dal'Olmo, Marlon Moser e Rafael Ehlert

Dados e onde está cada coisa no repositório

- **Projeto (Unidade 1):** classificar o gênero de um livro em PDF **sem lê-lo por inteiro**, lendo amostras de 15% a 30% das páginas por geração e interpolando as gerações.
- **Base (8 obras, 7 gêneros):** *Dracula* e *Frankenstein* (terror), *Pride and Prejudice* (romance), *The Adventures of Sherlock Holmes* (mistério), *Moby Dick* (ação/aventura), *Great Expectations* (drama), *The Picture of Dorian Gray* (filosófico) e *The Time Machine* (ficção científica), baixadas do Project Gutenberg e renderizadas como PDF pelo pipeline da Etapa 2: **1.134 páginas úteis, 2,61 milhões de caracteres**.
- **Amostragem (explicitada, como o enunciado permite):** as primeiras 150 páginas de cada PDF (*The Time Machine* tem 84). A unidade de análise é um **bloco de 3 páginas consecutivas** (~7 mil caracteres): **378 documentos** na base. Uma página sozinha é curta e ruidosa, e o livro inteiro dá só 8 pontos para agrupar.
- **Dados novos (holdout, 7 obras, 302 documentos):** *Dr Jekyll and Mr Hyde*, *Jane Eyre*, *The Mysterious Affair at Styles*, *Treasure Island*, *Little Women*, *Siddhartha* e *The War of the Worlds*, uma por gênero da base. Nunca entram no ajuste das representações nem no treino; servem para responder como o classificador se comporta com dados novos (questão 4) e completam o acervo da recomendação.
- **Rótulos:** gênero **curado manualmente** por obra (`src/librarian_ai/catalog.py`). O gabarito das APIs da Etapa 2 é ruidoso demais para treino (*Pride and Prejudice* sai como "Drama" no Open Library).
- **Código:** `unidade3/` (um módulo por tarefa: `representations.py`, `clustering.py`, `search.py`, `classification.py`, `extraction.py`). **Resultados:** `unidade3/results/` (figuras, tabelas CSV e um resumo por etapa). **Este documento e o script que o gera:** `unidade3/entrega/`. Para rodar: `python -m unidade3.run` (625 s na RTX 4060 Ti; resultados determinísticos, idênticos byte a byte entre execuções).

Tabela 1 — As quatro representações (`unidade3/representations.py`)

Representação	Vetor do documento	Ajuste
BoW	contagem dos termos (tokens de 3+ letras, sem stopwords PT/EN, min_df = 2); 11.816 dimensões	vocabulário do treino
TF-IDF	TF sublinear (1 + log tf) × IDF, normalizado; 11.816 dimensões	vocabulário + IDF do treino
Word2Vec	média dos vetores das palavras ponderada pelo IDF; skip-gram de 100 dimensões treinado no próprio corpus (gensim, semente fixa)	treino do Word2Vec
BERT	Sentence-BERT all-MiniLM-L6-v2 (BERT de 6 camadas): janelas de 180 palavras → mean pooling → média das janelas; 384 dimensões	nenhum (pré-treinado)

Trecho de código — documento como média dos vetores Word2Vec ponderada pelo IDF (unidade3/representations.py)

```
def transform(self, texts):
    wv = self.model.wv
    out = np.zeros((len(texts), self.vector_size), dtype=np.float64)
    for i, text in enumerate(texts):
        counts = Counter(w for w in analyze(text) if w in wv.key_to_index)
        if not counts:
            continue
        words = list(counts)
        weights = np.array([counts[w] * self.idf.get(w, 1.0) for w in words])
        out[i] = weights @ wv[words] / weights.sum()   # média ponderada pelo IDF
    return out
```

1) Atividades realizadas

Representações × tarefas

	BoW	TF-IDF	Word2Vec	BERT
Clusterização + PCA e visualização	✓	✓	✓	✓
Busca e recomendação	✓	✓	✓	✓
Classificação	✓	✓	✓	✓

Observações sobre a tabela:

- **Normalização comum:** antes de agrupar, buscar ou comparar, todos os vetores são normalizados (norma L2 = 1), de modo que todas as tarefas operam na geometria do cosseno. O `fit` de cada representação só vê textos de treino.
- **PCA:** a projeção 2D foi aplicada às quatro representações (Figura 2).
- **Classificação:** os rótulos vieram da curadoria por obra. Além da regressão logística, testamos um modelo de decisão (Random Forest), o mascaramento de nomes próprios e duas referências sem treino: o classificador **zero-shot por NLI** (`facebook/bart-large-mnli`, o backend do pipeline da Unidade 1) e o léxico TF-IDF do pipeline.
- **Busca:** além das quatro representações, uma busca **híbrida** que funde os rankings do TF-IDF e do BERT por *Reciprocal Rank Fusion*.

Tarefas de extração

Tarefa	Situação
Análise de sentimento	(X) Foi realizada ( ) Não foi realizada
Reconhecimento de Entidades Nomeadas	(X) Foi realizado ( ) Não foi realizado
Extração de Relações	(X) Foi realizada ( ) Não foi realizada

2) Clusters: qual representação e quantos clusters

Aplicamos o K-Means (10 inicializações, semente fixa) aos 378 documentos da base, em cada uma das quatro representações, para k de 2 a 12. Medimos a forma dos grupos com métricas **intracluster** (distância média de cada documento ao centroide do próprio grupo, a coesão) e **intercluster** (distância média entre centroides, a separação), além da silhueta (cosseno), do Davies-Bouldin e do Calinski-Harabasz, que combinam as duas. Também comparamos os grupos com o **livro** e o **gênero** de origem (pureza, ARI e NMI). Código: `unidade3/clustering.py`; resultados: `unidade3/results/01_clusterizacao.md`.

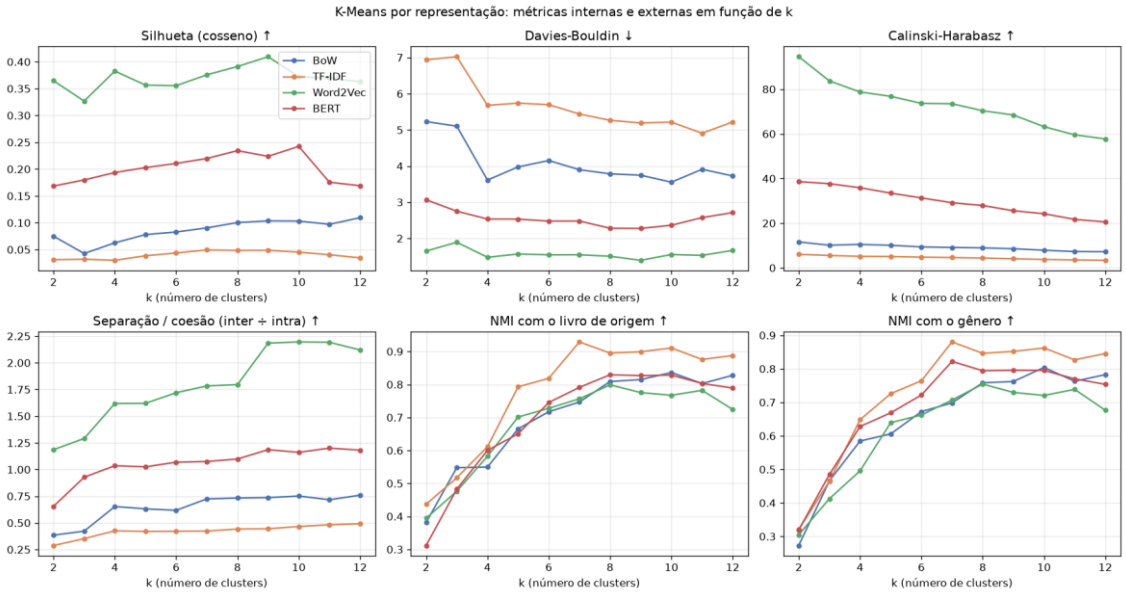


Figura 1 — Varredura de k: métricas internas (silhueta, Davies-Bouldin, Calinski-Harabasz e separação/coesão) e concordância com o livro e com o gênero (NMI).

Tabela 2 — Métricas no melhor k pela silhueta (critério interno, que não olha rótulos)

Representação	k	Silhueta	Davies-Bouldin ↓	Calinski-H.	Intra	Inter	Inter ÷ Intra	Pureza (livro)	NMI (livro)	NMI (gênero)
BoW	12	0,109	3,73	7,2	0,81	0,62	0,76	0,92	0,83	0,78
TF-IDF	7	0,049	5,44	4,6	0,92	0,39	0,42	0,91	0,93	0,88
Word2Vec	9	0,409	1,39	68,4	0,22	0,49	2,18	0,86	0,78	0,73
BERT	10	0,242	2,36	24,2	0,52	0,60	1,16	0,90	0,83	0,80

Tabela 3 — Métricas com k = 8 (o número de livros da base)

Representação	k	Silhueta	Davies-Bouldin ↓	Calinski-H.	Intra	Inter	Inter ÷ Intra	Pureza (livro)	NMI (livro)	NMI (gênero)
BoW	8	0,100	3,78	8,9	0,83	0,61	0,73	0,83	0,81	0,76
TF-IDF	8	0,048	5,26	4,4	0,92	0,41	0,44	0,93	0,90	0,85
Word2Vec	8	0,391	1,50	70,4	0,23	0,41	1,80	0,87	0,80	0,75
BERT	8	0,234	2,28	27,9	0,53	0,58	1,10	0,88	0,83	0,79

Interpretação das métricas intra e intercluster:

- **Pelas métricas internas, o Word2Vec "ganha" com folga:** grupos compactos (intra de 0,22), separação duas vezes maior que a coesão (inter ÷ intra = 2,18) e silhueta de 0,41. O TF-IDF fica no extremo oposto: intra de 0,92, perto do máximo para vetores unitários quase ortogonais, e silhueta de 0,05.
- **Isso é efeito da geometria de cada espaço, e não da qualidade dos grupos.** Em 11.816 dimensões esparsas, quase todos os pares de documentos são quase ortogonais e as distâncias se concentram (a "maldição da dimensionalidade"). O PCA mostra o mesmo: os dois primeiros eixos explicam só 3,4% da variância do TF-IDF, contra 43,7% do Word2Vec, cuja média de vetores comprime cada documento num espaço denso de 100 dimensões, onde tudo fica perto de tudo.
- **Conclusão sobre as métricas:** silhueta e Davies-Bouldin servem para escolher k **dentro** de uma representação, mas não para comparar representações entre si. Para isso usamos as métricas externas (NMI) e a leitura dos grupos.
- **As métricas internas não concordam sobre k.** A silhueta escolhe k = 12 no BoW, 7 no TF-IDF, 9 no Word2Vec e 10 no BERT, e o Calinski-Harabasz prefere sempre k = 2. Já a NMI de todas as representações sobe até k ≈ 7–8 e se estabiliza (Figura 1, painéis inferiores).

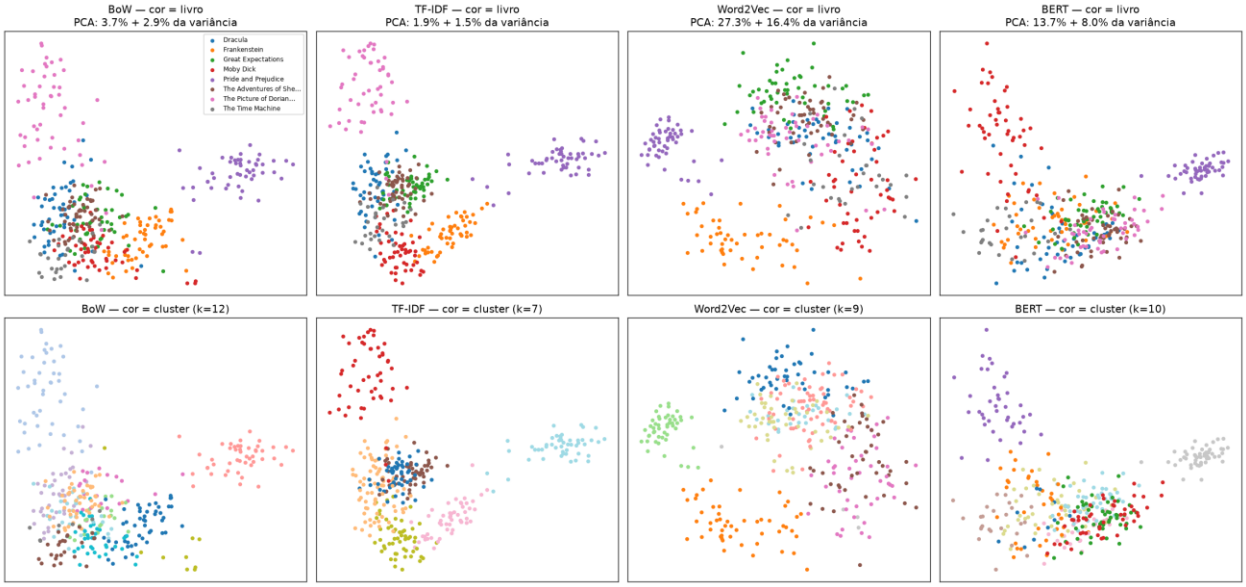


Figura 2 — PCA 2D dos 378 documentos. Em cima, cor = livro de origem; embaixo, cor = cluster no melhor k pela silhueta. O título de cada painel traz a variância explicada pelos dois eixos.

Leitura dos grupos. Para cada cluster, listamos os termos de maior peso TF-IDF em relação à média do corpus e os livros que o compõem:

Tabela 4 — Clusters do TF-IDF com k = 7 (o de maior NMI)

#	Docs	Composição (livro: documentos)	Termos distintivos
0	49	The Adventures of Sherlock Holmes (49)	holmes, sherlock, watson, street, case, remarked, police, baker
1	78	Dracula (48), The Time Machine (28), Great Expectations (1), The Adventures of Sherlock Holmes (1)	lucy, helsing, van, machine, arthur, jonathan, count, sleep
2	50	The Picture of Dorian Gray (50)	dorian, gray, harry, henry, basil, lord, hallward, sibyl
3	49	Great Expectations (49)	joe, havisham, pip, pumblechook, estella, biddy, wopsle, sister
4	50	Frankenstein (49), Pride and Prejudice (1)	clerval, feelings, felix, justine, cottage, misery, father, miserable
5	53	Moby Dick (50), Dracula (2), Frankenstein (1)	whale, queequeg, ship, captain, sea, whaling, ahab, peleg
6	49	Pride and Prejudice (49)	bingley, bennet, darcy, elizabeth, jane, illustration, collins, mrs

Tabela 5 — Dois clusters do BERT com k = 10 que juntam livros diferentes

#	Docs	Composição (livro: documentos)	Termos distintivos
1	36	Dracula (16), Moby Dick (12), Great Expectations (4), Frankenstein (2), The Picture of Dorian Gray (2)	count, bed, castle, landlord, queequeg, harpooneer, sleep, wolves
5	26	The Time Machine (19), Dracula (5), Frankenstein (2)	weena, machine, morlocks, sphinx, bronze, white, darkness, palace

- **TF-IDF, k = 7:** tem a maior NMI com o livro (0,93) e com o gênero (0,88). Cada cluster é praticamente um livro (*holmes, sherlock, watson*; *dorian, gray, harry, basil*; *whale, queequeg, ship*). A única fusão relevante junta *Dracula* (48) e *The Time Machine* (28) no cluster 1.
- **Os clusters reproduzem livros, e os nomes de personagens são o que mais pesa.** Como a base tem um livro por gênero, "agrupar por livro" e "agrupar por gênero" quase coincidem. O teste real é o terror, o único gênero com dois livros: **nenhuma** representação juntou *Dracula* e *Frankenstein* num mesmo cluster.
- **O BERT foi o único a formar um cluster temático entre livros.** O cluster 1 (k = 10) junta 16 documentos de *Dracula* e 12 de *Moby Dick* (*count, bed, castle, landlord, harpooneer, sleep, wolves*): são as cenas de "pernoite num lugar estranho", Harker no castelo do Conde e Ishmael na estalagem Spouter-Inn. Nenhuma representação baseada em palavras capturou essa semelhança de **situação narrativa**.
- **Clusters de ruído estrutural.** O BoW (cluster 9) e o Word2Vec (cluster 6) isolam as páginas de sumário e de abertura (*chapter, heading, contents, etymology*), exatamente o conteúdo que o agente da Unidade 1 deve aprender a evitar.
- **Mais clusters subdividem livros em segmentos reais.** Com k = 12, o BoW separa *Great Expectations* em "Joe, a forja e o Sr. Wopsle" e "Miss Havisham e Estella", e *The Time Machine* na moldura (o laboratório, o *Psychologist*, o *Editor*) e no mundo futuro (Weena, Morlocks, a Esfinge).

Conclusão. O **TF-IDF** gerou os clusters mais representativos e interpretáveis para estes dados (NMI de 0,93 com o livro e 0,88 com o gênero). O **BERT** foi o único a revelar semelhança temática entre livros diferentes. O **Word2Vec** tem as melhores métricas internas, mas mistura mais os livros: um dos seus clusters reúne documentos de 7 obras. A quantidade que melhor expressou as características originais dos dados foi **k = 7 a 8**, o número de gêneros e de livros: é onde a NMI de todas as representações atinge o patamar.

3) Busca: qualidade dos top-3 e top-5

Escrevemos dez consultas em linguagem natural, cada uma descrevendo uma cena de uma obra específica (ou, na consulta 9, um gênero). É relevante o documento da obra (ou do gênero) descrita. Para cada representação, a busca ordena os 378 documentos pelo cosseno com a consulta. O método **híbrido** funde os rankings do TF-IDF e do BERT por *Reciprocal Rank Fusion* (RRF). Para julgar os resultados lendo o texto, cada resultado traz a frase do documento com mais termos da consulta (`unidade3/results/02_busca.md`).

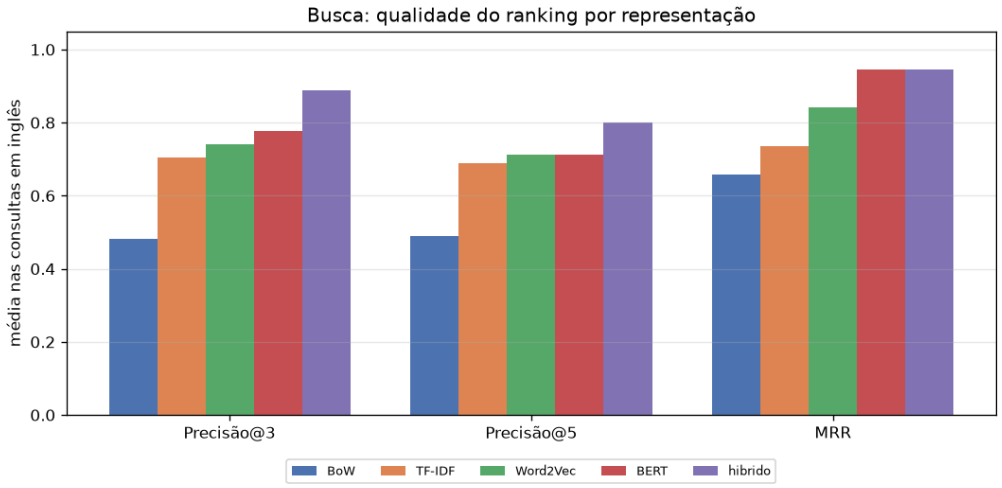


Figura 3 — Precisão@3, Precisão@5 e MRR médios nas 9 consultas em inglês.

Tabela 6 — Precisão nos 3 e nos 5 primeiros e posição do 1º relevante (média nas 9 consultas em inglês)

Método	Precisão@3	Precisão@5	MRR
BoW	48,1%	48,9%	0,66
TF-IDF	70,4%	68,9%	0,74
Word2Vec	74,1%	71,1%	0,84
BERT	77,8%	71,1%	0,94
Híbrido (TF-IDF + BERT, RRF)	88,9%	80,0%	0,94

Tabela 7 — Precisão@5 por consulta

#	Consulta	BoW	TF-IDF	W2V	BERT	Híbr.
1	a vampire who drinks human blood and sleeps in a coffin	60%	0%	40%	60%	60%
2	a scientist who creates a living creature from dead body parts	20%	0%	40%	60%	60%
3	a detective who solves a crime by observing small clues	80%	100%	80%	100%	100%
4	hunting a great white whale with harpoons on a ship	100%	100%	100%	100%	100%
5	a proud rich gentleman proposes marriage and is refused	0%	40%	60%	40%	40%
6	a machine that carries a man into the distant future	40%	100%	100%	100%	100%
7	a painted portrait that grows old while the young man stays beautiful	0%	80%	100%	100%	100%
8	a poor orphan boy helps an escaped convict in the marshes	80%	100%	100%	20%	80%
9	fear and dread in the dark night as something terrible approaches	60%	100%	20%	60%	80%
10	caça à baleia branca com arpões em alto-mar	0%	0%	0%	40%	0%

Tabela 8 — Consulta 1: "a vampire who drinks human blood and sleeps in a coffin" (relevante = Dracula)

Representação	5 primeiros (✓ = relevante)
BoW	✓ Dracula (p. 103-105); ✓ Dracula (p. 25-27); ✗ The Time Machine (p. 58-60); ✓ Dracula (p. 127-129); ✗ Frankenstein (p. 37-39)
TF-IDF	✗ Dorian Gray (p. 16-18); ✗ Frankenstein (p. 58-60); ✗ Moby Dick (p. 22-24); ✗ Moby Dick (p. 46-48); ✗ Moby Dick (p. 31-33)
Word2Vec	✗ Moby Dick (p. 67-69); ✗ Moby Dick (p. 64-66); ✓ Dracula (p. 73-75); ✓ Dracula (p. 148-150); ✗ Moby Dick (p. 127-129)
BERT	✓ Dracula (p. 106-108); ✗ Moby Dick (p. 46-48); ✓ Dracula (p. 109-111); ✓ Dracula (p. 121-123); ✗ Moby Dick (p. 73-75)
Híbrido (TF-IDF + BERT, RRF)	✗ Moby Dick (p. 46-48); ✓ Dracula (p. 127-129); ✓ Dracula (p. 139-141); ✓ Dracula (p. 103-105); ✗ Frankenstein (p. 58-60)

Tabela 9 — Consulta 5: "a proud rich gentleman proposes marriage and is refused" (relevante = Pride and Prejudice)

Representação	5 primeiros (✓ = relevante)
BoW	✗ Great Expectations (p. 139-141); ✗ Great Expectations (p. 106-108); ✗ Great Expectations (p. 70-72); ✗ Great Expectations (p. 73-75); ✗ Dorian Gray (p. 55-57)
TF-IDF	✗ Great Expectations (p. 139-141); ✗ Dorian Gray (p. 43-45); ✓ Pride and Prejudice (p. 37-39); ✓ Pride and Prejudice (p. 127-129); ✗ Great Expectations (p. 115-117)
Word2Vec	✓ Pride and Prejudice (p. 100-102); ✓ Pride and Prejudice (p. 124-126); ✗ Great Expectations (p. 139-141); ✓ Pride and Prejudice (p. 31-33); ✗ Great Expectations (p. 148-150)
BERT	✓ Pride and Prejudice (p. 124-126); ✓ Pride and Prejudice (p. 127-129); ✗ Dracula (p. 49-51); ✗ Dorian Gray (p. 55-57); ✗ Frankenstein (p. 4-6)
Híbrido (TF-IDF + BERT, RRF)	✓ Pride and Prejudice (p. 127-129); ✗ Great Expectations (p. 139-141); ✓ Pride and Prejudice (p. 37-39); ✗ Dorian Gray (p. 55-57); ✗ Frankenstein (p. 4-6)

Tabela 10 — Consulta 8: "a poor orphan boy helps an escaped convict in the marshes" (relevante = Great Expectations)

Representação	5 primeiros (✓ = relevante)
BoW	✓ Great Expectations (p. 28-30); ✗ Frankenstein (p. 61-63); ✓ Great Expectations (p. 43-45); ✓ Great Expectations (p. 118-120); ✓ Great Expectations (p. 40-42)
TF-IDF	✓ Great Expectations (p. 28-30); ✓ Great Expectations (p. 94-96); ✓ Great Expectations (p. 58-60); ✓ Great Expectations (p. 31-33); ✓ Great Expectations (p. 25-27)
Word2Vec	✓ Great Expectations (p. 31-33); ✓ Great Expectations (p. 94-96); ✓ Great Expectations (p. 55-57); ✓ Great Expectations (p. 91-93); ✓ Great Expectations (p. 88-90)
BERT	✗ Moby Dick (p. 82-84); ✓ Great Expectations (p. 28-30); ✗ Frankenstein (p. 88-90); ✗ Frankenstein (p. 100-102); ✗ Sherlock Holmes (p. 61-63)
Híbrido (TF-IDF + BERT, RRF)	✓ Great Expectations (p. 28-30); ✓ Great Expectations (p. 31-33); ✓ Great Expectations (p. 91-93); ✗ Frankenstein (p. 61-63); ✓ Great Expectations (p. 94-96)

Tabela 11 — Consulta 9: "fear and dread in the dark night as something terrible approaches" (relevante = qualquer livro de terror)

Representação	5 primeiros (✓ = relevante)
BoW	✗ The Time Machine (p. 52-54); ✓ Dracula (p. 76-78); ✗ Sherlock Holmes (p. 127-129); ✓ Dracula (p. 106-108); ✓ Dracula (p. 73-75)
TF-IDF	✓ Dracula (p. 34-36); ✓ Dracula (p. 31-33); ✓ Dracula (p. 76-78); ✓ Dracula (p. 40-42); ✓ Dracula (p. 73-75)
Word2Vec	✗ The Time Machine (p. 52-54); ✗ The Time Machine (p. 40-42); ✗ The Time Machine (p. 34-36); ✓ Dracula (p. 73-75); ✗ The Time Machine (p. 31-33)
BERT	✓ Dracula (p. 40-42); ✓ Dracula (p. 31-33); ✗ Dorian Gray (p. 97-99); ✗ The Time Machine (p. 49-51); ✓ Dracula (p. 10-12)
Híbrido (TF-IDF + BERT, RRF)	✓ Dracula (p. 31-33); ✓ Dracula (p. 40-42); ✓ Dracula (p. 76-78); ✗ The Time Machine (p. 52-54); ✓ Dracula (p. 34-36)

Análise crítica:

- **BoW** é dominado por palavras frequentes. Para a proposta de casamento recusada, devolveu quatro trechos de *Great Expectations* ("Havisham was very rich and very proud") e um de *Dorian Gray*: precisão@5 de 0%.
- **TF-IDF** acerta quando a consulta tem termos raros e específicos (*convict, marshes*: 5 de 5 na consulta 8), mas cai em **casamentos lexicais espúrios**. Na consulta do vampiro, não trouxe nenhum trecho de *Dracula*: a palavra *vampire* quase não aparece nas primeiras 150 páginas (nem entrou no vocabulário do Word2Vec, que exige 3 ocorrências), e *coffin* casou com *Miriam Coffin or the Whale Fisherman* e com **Peter Coffin**, o estalajadeiro de *Moby Dick*.
- **Word2Vec** generaliza por vizinhança semântica (*whale → sperm, ocean*; *portrait → painter, sitter*), mas a média de vetores dilui cenas específicas. Na consulta 9, 4 dos 5 resultados vieram de *The Time Machine* ("the fear of the little Upperworld people"). Pelo critério automático a precisão@5 é 20%, mas os trechos **falam de medo no escuro**: aqui o critério "ser de um livro de terror" subestima a busca.
- **BERT** tem o melhor MRR (0,94): o primeiro resultado quase sempre está certo e responde à **cena**, não às palavras. Na proposta de casamento, trouxe "this offer of marriage you have refused?" e "by refusing your hand". Ele erra quando a consulta depende de termos específicos: na consulta 8, o 1º resultado foi o esqueleto do "poor little Indian" de *Moby Dick* (precisão@5 de 20%, contra 100% do TF-IDF).

- **Híbrido:** como TF-IDF e BERT erram em consultas **diferentes**, a fusão corrige os dois e eleva a precisão@3 de 77,8% (BERT) para 88,9%. É a resposta empírica a "como poderiam ser combinados".
- **Consulta em português** ("caça à baleia branca com arpões em alto-mar", consulta 10): BoW e TF-IDF casam o "mar" de *alto-mar* com o verbo inglês *to mar* ("would mar his body"), um falso cognato. O BERT acerta *Moby Dick* em 2 de 5, mas só porque recupera páginas de **sumário** ("CHAPTER 96") cujos títulos têm *whale*: relevante pelo critério automático, inútil para o usuário. O híbrido perde até esses dois.

Os resultados são utilizáveis em contexto real? Para localizar um trecho num acervo conhecido e em inglês, o híbrido é utilizável: em média, 89% dos 3 primeiros resultados são da obra certa, e o primeiro resultado é da obra certa em 8 das 9 consultas (MRR de 0,94). Com ressalvas: (i) blocos de 3 páginas são grandes demais para apontar a passagem exata; (ii) a busca não funciona entre idiomas; (iii) a relevância aqui é "ser da obra certa", um critério mais leniente que "responder à consulta".

Como melhorar: trechos menores (parágrafos); reordenação com *cross-encoder*; um modelo multilíngue (`paraphrase-multilingual-MiniLM`) para consultas em português; BM25 no lugar do TF-IDF; expansão da consulta com os vizinhos do Word2Vec; e um filtro de sumários e páginas de rosto antes da indexação.

Trecho de código — fusão de rankings (unidade3/search.py)

```
def reciprocal_rank_fusion(rankings: list[list[int]], k: int = 60) -> list[int]:
    """Funde rankings somando ``1 / (k + posicao)`` de cada documento."""
    score: dict[int, float] = {}
    for ranking in rankings:
        for pos, doc in enumerate(ranking, start=1):
            score[doc] = score.get(doc, 0.0) + 1.0 / (k + pos)
    return sorted(score, key=lambda d: (-score[d], d))
```

Recomendação

Sobre o **acervo** (base + holdout: 15 livros, 680 documentos, ao menos dois livros por gênero), o vetor de cada livro é a média dos seus documentos, e a recomendação é o livro mais próximo. Também medimos o "mais como este" por trecho: entre os 5 documentos mais parecidos de **outros** livros, a fração do mesmo gênero.

Tabela 12 — Recomendação de livros e de trechos

Representação	Acerto@1 (recomendado é do mesmo gênero)	Acerto@3	"Mais como este" precisão@5
BoW	53,3%	60,0%	21,2%
TF-IDF	46,7%	66,7%	21,4%
Word2Vec	46,7%	80,0%	33,4%
BERT	40,0%	73,3%	22,0%

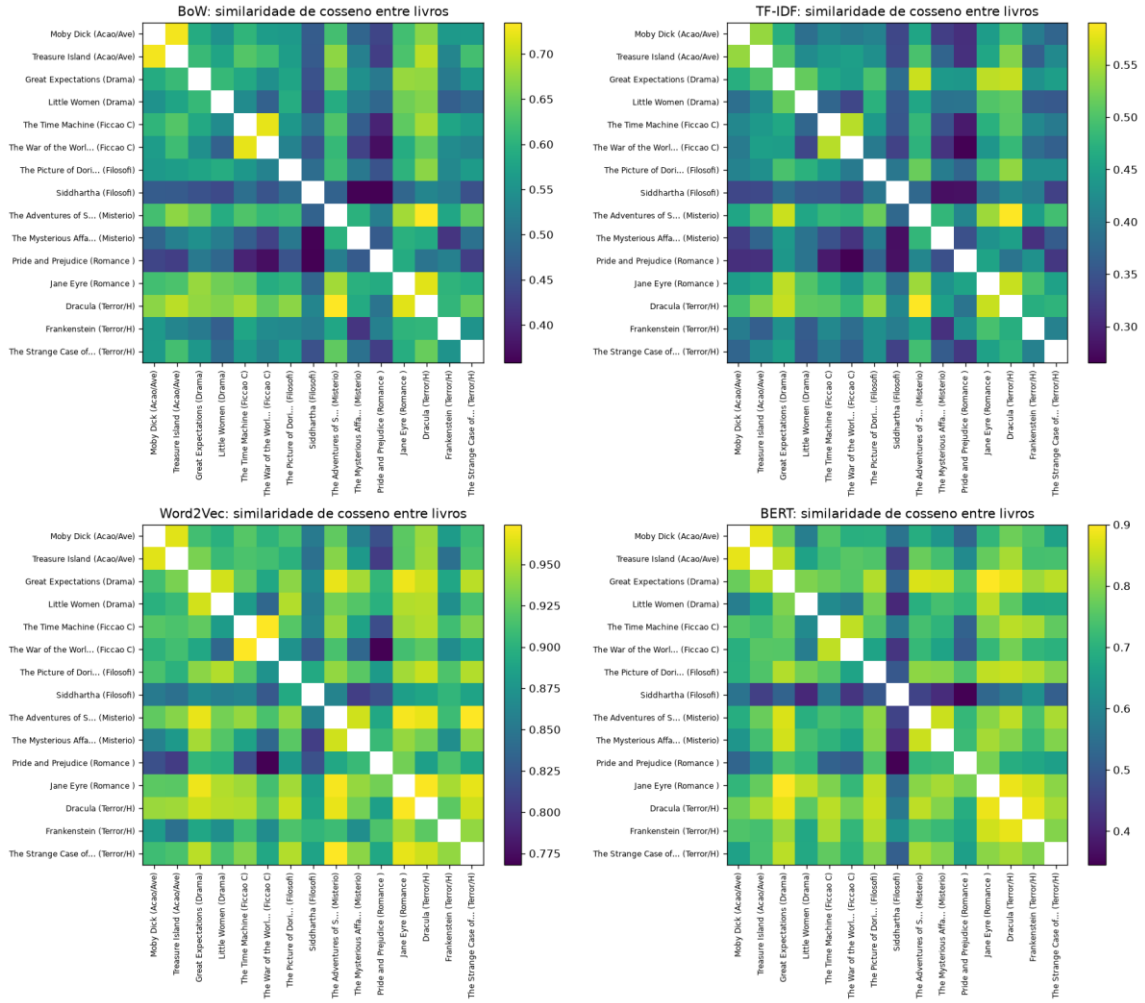


Figura 4 — Similaridade de cosseno entre os 15 livros do acervo, por representação, ordenados por gênero.

- Os pares *Moby Dick* ↔ *Treasure Island* e *The Time Machine* ↔ *The War of the Worlds* são recomendados mutuamente em **todas** as representações.
- Há erros que fazem sentido: para *Dr Jekyll and Mr Hyde* (terror), o TF-IDF e o Word2Vec recomendam *Sherlock Holmes*, e a novela de fato é estruturada como a investigação do advogado Utterson.
- O defeito mais visível é o **hubness**: no BoW e no TF-IDF, *Dracula* aparece entre os 3 recomendados de 13 dos outros 14 livros; no Word2Vec e no BERT, *Jane Eyre* é o 1º recomendado de 4 livros. É um fenômeno conhecido de espaços vetoriais de alta dimensão, mitigável com centralização dos vetores ou CSLS.
- O Word2Vec tem o melhor acerto@3 (80%) e o melhor "mais como este" (33%, contra 14% ao acaso com 7 gêneros).

4) Classificação

Sim, foi possível treinar um classificador. Treinamos **regressão logística** (modelo linear) e **Random Forest** (modelo de decisão, um conjunto de 300 árvores), ambos com classes de peso balanceado, sobre cada representação. Usamos dois protocolos (`unidade3/classification.py`):

- **Validação cruzada estratificada em 5 dobras na base:** documentos de um mesmo livro caem no treino e no teste.
- **Holdout (dados novos):** treino na base inteira e teste nos 302 documentos dos 7 livros novos. As representações são ajustadas **só** na base. O veredito por livro agrega as distribuições dos seus documentos com `aggregation.aggregate`, a mesma função que o pipeline usa entre gerações.
- **Mascaramento de nomes próprios:** palavras que quase sempre aparecem capitalizadas no meio da frase (Harker, Darcy, Collins) viram "X", detectadas livro a livro, sem modelo.

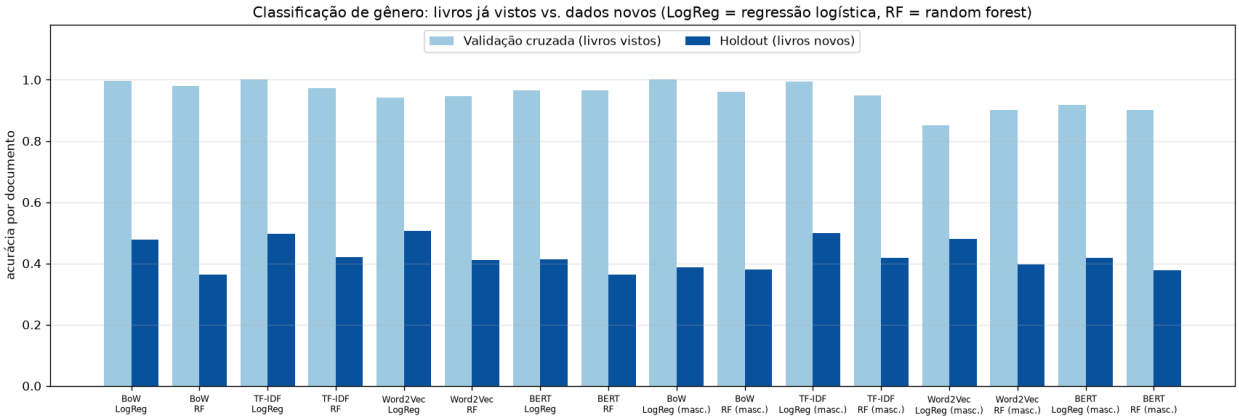


Figura 5 — Acurácia por documento: validação cruzada (livros já vistos) × holdout (livros novos).

Tabela 13 — Classificação de gênero: validação cruzada e dados novos (7 gêneros; acaso = 14,3%)

Representação	Modelo	Nomes masc.	Acurácia VC	Acurácia holdout	F1 macro holdout	Livros novos certos
BoW	Reg. logística	não	99,7%	47,7%	44,5%	4/7
BoW	Random Forest	não	97,9%	36,4%	35,8%	3/7
TF-IDF	Reg. logística	não	100,0%	49,7%	45,2%	4/7
TF-IDF	Random Forest	não	97,4%	42,1%	40,4%	3/7
Word2Vec	Reg. logística	não	94,2%	50,7%	43,8%	5/7
Word2Vec	Random Forest	não	94,7%	41,1%	37,7%	4/7
BERT	Reg. logística	não	96,6%	41,4%	38,5%	5/7
BERT	Random Forest	não	96,6%	36,4%	34,9%	4/7
BoW	Reg. logística	sim	100,0%	38,7%	35,1%	4/7
BoW	Random Forest	sim	96,0%	38,1%	37,9%	3/7
TF-IDF	Reg. logística	sim	99,5%	50,0%	44,8%	5/7
TF-IDF	Random Forest	sim	95,0%	41,7%	38,6%	3/7
Word2Vec	Reg. logística	sim	85,2%	48,0%	43,1%	4/7
Word2Vec	Random Forest	sim	90,2%	39,7%	36,6%	3/7
BERT	Reg. logística	sim	91,8%	41,7%	39,5%	3/7
BERT	Random Forest	sim	90,2%	37,7%	36,9%	3/7
Léxico TF-IDF (sem treino)	—	—	—	38,1%	36,8%	4/7
Zero-shot BART-MNLI (sem treino)	—	—	—	20,9%	18,8%	2/7

Tabela 14 — Veredito por livro novo (RL = regressão logística, RF = Random Forest; última coluna: acertos entre as 16 configurações supervisionadas)

Livro	Gênero	TF-IDF + RL	TF-IDF + RL (masc.)	Word2Vec + RL	BERT + RL	TF-IDF + RF	Zero-shot	Acertos
Jane Eyre	Romance	✗ Terror	✗ Terror	✗ Terror	✗ Drama	✗ Terror	✗ Terror	1/16
Little Women	Drama	✗ Terror	✓ Drama	✓ Drama	✓ Drama	✗ Terror	✗ Terror	6/16
Siddhartha	Filosófico	✗ Terror	✗ Terror	✗ Terror	✗ Terror	✗ Terror	✓ Filosófico	0/16
The Mysterious Affair at Styles	Mistério	✓ Mistério	✓ Mistério	✓ Mistério	✓ Mistério	✗ Terror	✗ Terror	10/16
Dr Jekyll and Mr Hyde	Terror	✓ Terror	✓ Terror	✓ Terror	✓ Terror	✓ Terror	✓ Terror	11/16
The War of the Worlds	Ficção científica	✓ Ficção científica	✓ Ficção científica	✓ Ficção científica	✓ Ficção científica	✓ Ficção científica	✗ Terror	16/16
Treasure Island	Aventura	✓ Aventura	✓ Aventura	✓ Aventura	✓ Aventura	✓ Aventura	✗ Terror	16/16

Como se comportou com dados novos. Há uma **queda de cerca de 50 pontos**: de 94% a 100% de acurácia na validação cruzada (sem máscara) para 36% a 51% por documento nos livros novos (o acaso, com 7 gêneros, fica em 14%). No nível do livro, os melhores modelos acertam **5 de 7** obras inéditas. *Treasure Island* e *The War of the Worlds* são acertados pelas 16 configurações supervisionadas; *The Mysterious Affair at Styles*, por 10. O erro sistemático é *Siddhartha* (filosófico), previsto como terror por **todas** as 16: o único exemplo de "filosófico" no treino é *Dorian Gray*, um romance de salão londrino que não se parece com a busca espiritual de Siddhartha. *Jane Eyre* (romance) também sai como terror em 12 das 16, e a obra de fato tem forte componente gótico (o Quarto Vermelho, a mulher no sótão de Thornfield).

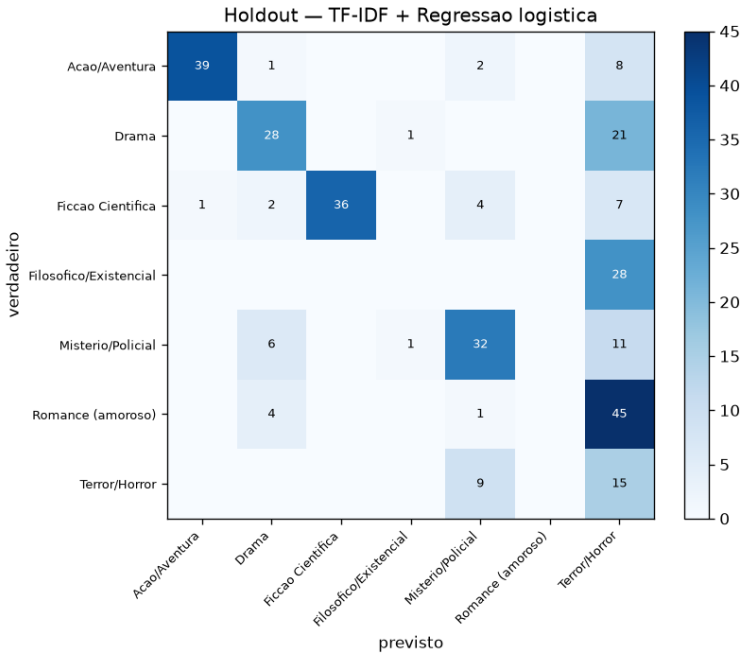


Figura 6 — Matriz de confusão no holdout da melhor configuração (TF-IDF + regressão logística): o terror absorve os erros, inclusive os 28 documentos de Siddhartha.

Por que a validação cruzada engana. Os termos de maior peso da regressão logística sobre TF-IDF mostram o que o modelo aprendeu:

Tabela 15 — Termos de maior peso por gênero (TF-IDF + regressão logística)

Gênero	Sem mascarar nomes	Com nomes mascarados
Ação/aventura	whale, queequeg, ship, captain, whaling, sea, ahab, peleg, whales, thou	whale, ship, captain, chapter, whaling, sea, thou, whales, voyage, harpooneer
Drama	joe, havisham, pip, pumblechook, estella, biddy, wopsle, sister, boy, pocket	sister, boy, kitchen, pocket, marshes, forge, gate, returned, gentleman, don
Ficção científica	machine, traveller, weena, morlocks, sphinx, psychologist, filby, bronze, editor, medical	machine, sphinx, space, palace, bronze, lever, white, travelling, matches, dimensions
Filosófico	dorian, gray, henry, harry, basil, lord, hallward, sibyl, don, vane	don, lad, art, life, portrait, picture, wonderful, murmured, painter, charming
Mistério	holmes, sherlock, watson, street, case, police, remarked, matter, doctor, baker	street, case, police, remarked, doctor, matter, visitor, singular, stepfather, miss
Romance	bennet, bingley, darcy, elizabeth, jane, collins, illustration, miss, mrs, lucas	herself, ladies, sisters, daughters, agreeable, girls, party, replied, lady, ball
Terror	lucy, helsing, van, arthur, count, whilst, jonathan, mina, sleep, heart	whilst, sleep, diary, heart, poor, cause, around, castle, death, sweet

Sem a máscara, o classificador é um **detector de personagens**: acerta 100% em documentos de livros conhecidos e não tem como transferir isso para um livro novo. Com a máscara, os termos passam a descrever o gênero (*ladies, sisters, ball* no romance; *portrait, painter, art* no filosófico), e o TF-IDF com regressão logística sobe de 4 para 5 livros novos certos. A máscara **não** ajuda o BERT (cai de 5 para 3): ele já codifica o contexto, e trocar nomes por "X" degrada as frases que recebe.

Alguma representação favorece classificações mais precisas? Sim:

- **TF-IDF e Word2Vec com modelo linear** são as melhores combinações em dados novos (F1 macro de 45% e 44%; acurácia de até 51%). O TF-IDF tem a vantagem de ser interpretável e de melhorar com a máscara de nomes.
- **O BERT não lidera** com 378 exemplos. O MiniLM foi treinado para similaridade semântica, não para estilo ou gênero, e um classificador linear em cima dele tem pouca informação para separar 7 gêneros. Ainda assim, empata em livros certos (5/7).
- **O BoW** perde para o TF-IDF sempre que há livros novos: sem o IDF, palavras frequentes dominam.

Modelos de linguagem e modelos de decisão. Usamos os dois:

- **Modelo de decisão (Random Forest):** teve acurácia menor que a regressão logística no holdout em **todas** as 8 combinações (de 0,6 a 11,3 pontos), apesar da validação cruzada equivalente. As árvores escolhem poucos atributos muito discriminativos, justamente os nomes próprios, e sobreajustam.
- **BERT como extrator de características:** o MiniLM congelado (mean pooling) alimenta a regressão logística e a Random Forest.
- **Zero-shot por NLI** (`bart-large-mnli`), o backend do pipeline da Unidade 1, com a calibração contextual e o *sharpening* configurados no pipeline. Sem nenhum treino, teve o pior desempenho (20,9% de acurácia, 2/7 livros): rotulou 224 dos 302 documentos como terror, o mesmo **colapso de modo** documentado no README do pipeline. Ainda assim, foi o **único** método a acertar *Siddhartha*, porque julga o texto contra a descrição do gênero e não contra exemplos de treino. O backend por LLM (Claude via API) existe no pipeline, mas não foi executado por exigir chave de API paga.

Trecho de código — avaliação com dados novos (unidade3/classification.py)

```
def evaluate_holdout(X_train, y_train, X_test, test_docs: list[Document], model_name: str, seed: int = 42) ->
dict:
    """Treina na base e avalia no holdout. X_train/X_test vêm de uma representação
    ajustada SÓ com a base: vocabulário, IDF e Word2Vec nunca veem o holdout."""
    model = make_model(model_name, seed).fit(X_train, y_train)
    y_test = np.array([d.genre for d in test_docs])
    proba = model.predict_proba(X_test)
    pred = model.classes_[np.argmax(proba, axis=1)]
    dists = to_taxonomy(proba, model.classes_)
    return {
        **doc_metrics(y_test, pred),
        "pred": pred,
        "books": book_verdicts(dists, test_docs),
        "model": model,
        "classes": list(model.classes_),
    }
```

5) Análise de sentimentos, NER e extração de relações

Sim, as três se aplicam aos dados, com ressalvas diferentes. Aplicamos as três aos 8 livros da base com modelos BERT pré-treinados, sem nenhum rótulo do corpus (`unidade3/extraction.py`). Cada modelo roda em fp16 na GPU e é liberado antes do próximo, para caber nos 8 GB de VRAM.

Análise de sentimentos — aplicável, com ressalvas

DistilBERT ajustado no SST-2 (`distilbert-base-uncased-finetuned-sst-2-english`), aplicado frase a frase. A valência de cada página é P(positivo) − P(negativo), com média sobre as frases; a sequência de páginas forma o "arco emocional" do livro.

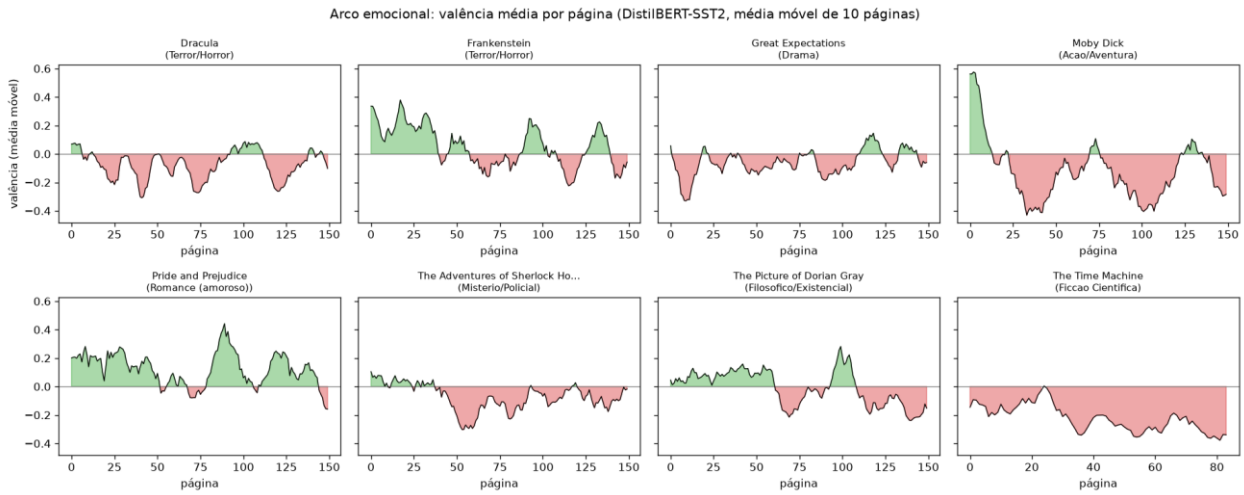


Figura 7 — Arco emocional: valência média por página, com média móvel de 10 páginas.

Tabela 16 — Valência por livro (ordenada da mais negativa para a mais positiva)

Livro	Gênero	Valência média	Páginas negativas	Página mais negativa	Página mais positiva
The Time Machine	Ficção científica	-0,222	81%	33	1
Moby Dick	Ação/aventura	-0,124	68%	38	2
Dracula	Terror	-0,077	66%	42	34
Sherlock Holmes	Mistério	-0,073	58%	58	2
Great Expectations	Drama	-0,059	61%	12	1
Dorian Gray	Filosófico	-0,008	56%	143	101
Frankenstein	Terror	0,054	45%	105	34
Pride and Prejudice	Romance	0,124	32%	15	122

- **Coerente nos extremos:** o romance é o livro mais positivo (32% de páginas negativas), e a viagem a um futuro decadente, o mais negativo (81%).
- **Os arcos mostram estrutura narrativa.** *Dorian Gray* é positivo até a página ~60 e negativo depois. *Frankenstein* começa positivo, com as cartas de Walton e a infância feliz de Victor.
- **A valência não separa gêneros sozinha:** *Frankenstein*, de terror, é mais positivo que *Sherlock Holmes*. O modelo foi treinado em críticas de cinema, não capta a ironia de Austen e se confunde com a linguagem do século XIX. As primeiras páginas de *Moby Dick* saem muito positivas, mas não são narrativa: são o sumário e as seções *Etymology* e *Extracts* (a página mais positiva é a 2).
- **Uso possível:** característica adicional para o classificador e sinal por segmento para o agente da Unidade 1, não um classificador de gênero.

Reconhecimento de entidades nomeadas — aplicável, com bons resultados

`dslim/bert-base-NER` (PER, LOC, ORG, MISC), frase a frase, com `aggregation_strategy="first"`: com `"simple"`, os nomes quebrados pelo WordPiece saíam truncados ("Lucy West", "Van Hels", "Miss Bing"). Nomes completos e curtos são unificados ("Lucy Westenra" → "Lucy").

Tabela 17 — Entidades por livro: contagem por tipo, personagens e lugares mais citados

Livro	PER	LOC	ORG	MISC	Personagens mais citados	Lugares mais citados
Dracula	757	272	31	125	Lucy (191), Van Helsing (95), Arthur (77), Jonathan (66), Mina (41)	London (29), Whitby (19), Bistritz (9)
Frankenstein	437	236	6	90	Elizabeth (55), Felix (47), Justine (46), Clerval (41), Safie (23)	Geneva (24), England (15), Ingolstadt (13)
Great Expectations	1459	82	28	67	Joe (481), Pip (139), Biddy (121), Pumblechook (91), Wopsle (87)	London (29), High Street (5), Little Britain (3)
Moby Dick	709	268	57	255	Queequeg (113), Bildad (71), Ahab (54), Peleg (54), Jonah (52)	Nantucket (34), New Bedford (14), Cape Horn (9)
Pride and Prejudice	1462	149	14	20	Elizabeth (209), Darcy (172), Bennet (155), Bingley (147), Jane (112)	Netherfield (41), Longbourn (22), Meryton (21)
Sherlock Holmes	937	424	68	99	Holmes (317), Watson (63), McCarthy (36), Clair (27), Lestrade (22)	London (26), Baker Street (22), St (19)
Dorian Gray	1373	198	16	169	Dorian (334), Basil (138), Harry (137), Henry (136), Hallward (51)	London (18), England (16), Paris (15)
The Time Machine	92	50	11	185	Weena (54), Filby (16), Nature (3), Blank (2), Watchett (2)	Underworld (10), Space (7), Thames (4)

- **Os personagens e lugares batem com a leitura dos livros**: 7.226 menções a pessoas nos 8 livros, com os protagonistas no topo (Elizabeth e Darcy; Holmes e Watson; Queequeg, Ahab; Netherfield, Longbourn, Baker Street, Nantucket).
- **Os erros se concentram em The Time Machine**, que tem poucos personagens nomeados (o narrador não tem nome): 185 entidades MISC contra 92 PER, e substantivos abstratos capitalizados viram entidades (*Nature*, *Space*, *Time*, *Underworld*).
- **O NER validou a heurística de nomes** usada na máscara da classificação: de 78% a 96% dos nomes detectados pela heurística aparecem como entidade (58% em *The Time Machine*).

Extração de relações — aplicável aos personagens

Fizemos a extração em duas etapas: (1) a **coocorrência** de personagens (PER) na mesma frase define *quem* se relaciona; (2) um modelo **NLI** (`bart-large-mnli`) testa hipóteses como "Darcy is in love with Elizabeth" contra as frases em que o par aparece (extração de relações por implicação textual, Sainz et al., 2021). O NLI

tem viés a priori: com uma premissa vazia, já dá 0,44 para "familiar". Por isso aplicamos a mesma calibração contextual do classificador zero-shot: o score é P(implicação | evidência) − P(implicação | premissa vazia).

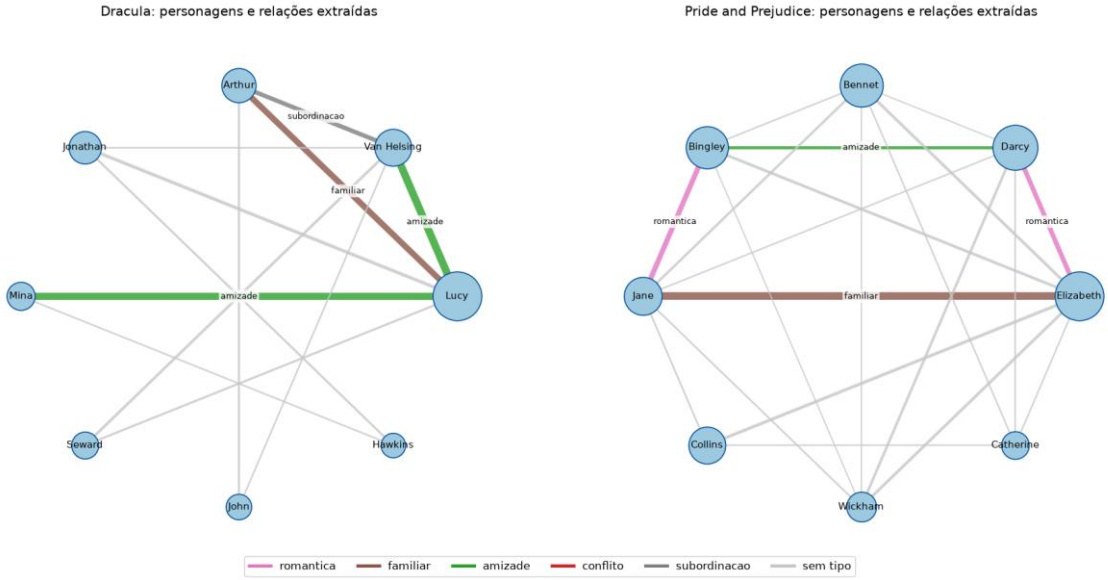


Figura 8 — Rede de personagens de Dracula e de Pride and Prejudice: espessura = coocorrências; cor = relação extraída.

Tabela 18 — Os 5 pares que mais coocorrem em cada livro, a relação extraída e a conferência manual

Livro	Par	Coocorr.	Relação extraída	Conferência
Dracula	Lucy — Van Helsing	12	amizade	✗ médico e paciente
Dracula	Lucy — Mina	11	amizade	✓ amigas íntimas
Dracula	Arthur — Lucy	9	familiar	✗ noivos (romântica ficou em 2º)
Dracula	Arthur — Van Helsing	6	subordinação	✗ aliados na caça ao Conde
Dracula	Arthur — Quincey	4	amizade	✓ amigos
Frankenstein	Agatha — Felix	11	familiar	✓ irmãos
Frankenstein	Felix — Safie	8	subordinação	✗ casal apaixonado
Frankenstein	Agatha — Safie	5	amizade	✓ Agatha acolhe Safie
Frankenstein	Clerval — Elizabeth	5	amizade	✓ amigos de infância
Frankenstein	Justine — William	5	familiar	parcial: criada da família, acusada da morte dele
Great Expectations	Joe — Pip	56	amizade	✓ cunhado e melhor amigo
Great Expectations	Biddy — Joe	16	amizade	✓ amigos
Great Expectations	Estella — Joe	7	familiar	✗ sem relação direta
Great Expectations	Estella — Miss Havisham	6	amizade	✗ filha adotiva
Great Expectations	Joe — Wopsle	6	amizade	✓ conhecidos da vila
Moby Dick	Bildad — Peleg	26	amizade	✓ sócios e velhos companheiros
Moby Dick	Ahab — Stubb	8	subordinação	✓ capitão e imediato
Moby Dick	Queequeg — Yojo	7	amizade	✗ Yojo é o ídolo de Queequeg
Moby Dick	Elijah — Queequeg	3	—	— sem relação; o modelo se absteve
Moby Dick	Ahab — Bildad	2	amizade	parcial: capitão e armador
Pride and Prejudice	Elizabeth — Jane	29	familiar	✓ irmãs
Pride and Prejudice	Bingley — Jane	18	romântica	✓ casal
Pride and Prejudice	Darcy — Elizabeth	16	romântica	✓ casal
Pride and Prejudice	Bingley — Darcy	9	amizade	✓ amigos
Pride and Prejudice	Charlotte — Elizabeth	9	familiar	✗ amigas
Sherlock Holmes	Holmes — Watson	7	amizade	✓ amigos
Sherlock Holmes	Holmes — McCarthy	3	amizade	✗ Holmes investiga o caso
Sherlock Holmes	McCarthy — Turner	3	subordinação	parcial: inquilino e senhorio (chantagem)
Sherlock Holmes	Holmes — Irene Adler	2	familiar	✗ adversários
Sherlock Holmes	Holmes — John Clay	2	conflito	✓ detetive e criminoso
Dorian Gray	Dorian — Henry	23	amizade	✓ amigos
Dorian Gray	Basil — Henry	11	amizade	✓ amigos
Dorian Gray	Dorian — Hallward	11	subordinação	✗ amigos; pintor e modelo
Dorian Gray	Basil — Dorian	10	amizade	✓ amigos
Dorian Gray	Dorian — Harry	10	amizade	✓ amigos (Harry = Lord Henry)
The Time Machine	Blank — Chose	1	amizade	✗ ruído do NER
The Time Machine	Blank — Dash	1	amizade	✗ ruído do NER
The Time Machine	Chose — Dash	1	—	— ruído do NER; abstenção
The Time Machine	Homer — Plato	1	familiar	✗ citação, não personagens

- **Conferência de todos os 39 pares:** em 2 o modelo não atribuiu relação; dos 37 tipados, **20 estão corretos (54%)**, 3 parcialmente corretos e 14 errados. Sem os 3 de *The Time Machine* (ruído herdado do NER), a precisão sobe para 59%.
- **Acertos claros:** os dois casais de *Pride and Prejudice* (Darcy—Elizabeth e Bingley—Jane como românticas), as irmãs Elizabeth e Jane, Holmes—Watson (amizade), Holmes—John Clay (conflito: o criminoso de *The Red-Headed League*) e Ahab—Stubb (subordinação).
- **Erros vêm de evidência ambígua ou de rótulo vizinho:** Arthur e Lucy são noivos, mas as frases falam da família dela ("romântica" ficou em 2º); Charlotte e Elizabeth são amigas, mas as frases falam das famílias Lucas e Bennet. Yojo, o ídolo de Queequeg, foi tomado por pessoa pelo NER.
- **Para a classificação de gênero, a relação é um sinal indireto mas plausível:** relações românticas dominam *Pride and Prejudice*, e conflito ou amizade em torno de um investigador marca o mistério.

Trecho de código — tipagem de relações por NLI calibrado (unidade3/extraction.py)

```
RELATIONS = {
    "romantica": "{a} is in love with {b}.",
    "familiar": "{a} and {b} are members of the same family.",
    "amizade": "{a} and {b} are friends.",
    "conflito": "{a} and {b} are enemies.",
    "subordinacao": "{a} works for {b}.",
}

def classify(self, a: str, b: str, evidence: list[str]) -> dict:
    """Scores brutos, prior, scores calibrados e a relação vencedora."""
    raw = self._entailment(" ".join(evidence[: self.max_sentences]), a, b)
    prior = self.prior(a, b)  # implicação média com premissas sem conteúdo: o viés do modelo
    calibrated = {k: raw[k] - prior[k] for k in RELATIONS}
    best = max(calibrated, key=calibrated.get)
    return {"raw": raw, "prior": prior, "calibrated": calibrated,
            "relation": best if calibrated[best] > 0 else None}
```

6) As técnicas auxiliam o projeto da Unidade 1?

Na Unidade 1, propusemos o *Librarian AI*: classificar o gênero de um livro em PDF lendo só uma fração das páginas, escolhidas por um agente de aprendizado por reforço, com várias gerações de leitura interpoladas até a distribuição de gêneros convergir. **Sim, as técnicas ajudam**, e de forma concreta:

Tabela 19 — Proposta da Unidade 1 × o que as técnicas da Unidade 3 mostraram

Proposta da Unidade 1	O que foi feito e medido	Técnica
Classificador de gênero do pipeline (zero-shot BART-MNLI)	Acertou 2 de 7 livros novos e colapsou em terror. Uma regressão logística sobre TF-IDF com nomes mascarados, treinada com os nossos dados, acertou 5 de 7, sem GPU	TF-IDF, regressão logística, NER
Ler só 15–30% do livro por geração e interpolar as gerações	Uma geração isolada acerta 64% das vezes; a interpolação das 10 gerações chega a 5/7 livros, o mesmo resultado de ler o livro inteiro	Classificação + aggregation.aggregate
Parada antecipada quando a distribuição converge (JSD < 0,01)	A JSD entre agregações consecutivas já fica abaixo de 0,01 na 2ª geração e chega à ordem de 10^{-5} por volta da 5ª	Divergência de Jensen-Shannon
Agente de RL que evita páginas pouco informativas	Clusters próprios de sumário e páginas de rosto; o sentimento das primeiras páginas de Moby Dick denuncia o sumário	Clusterização, sentimento
Robustez a nomes próprios de ficção	A máscara de nomes (validada pelo NER) transformou os pesos do classificador de personagens em vocabulário de gênero	NER, heurística de nomes
Recomendar livros parecidos (extensão)	Vizinhos por cosseno no acervo; pares Moby Dick ↔ Treasure Island e Time Machine ↔ War of the Worlds em todas as representações	Busca, recomendação

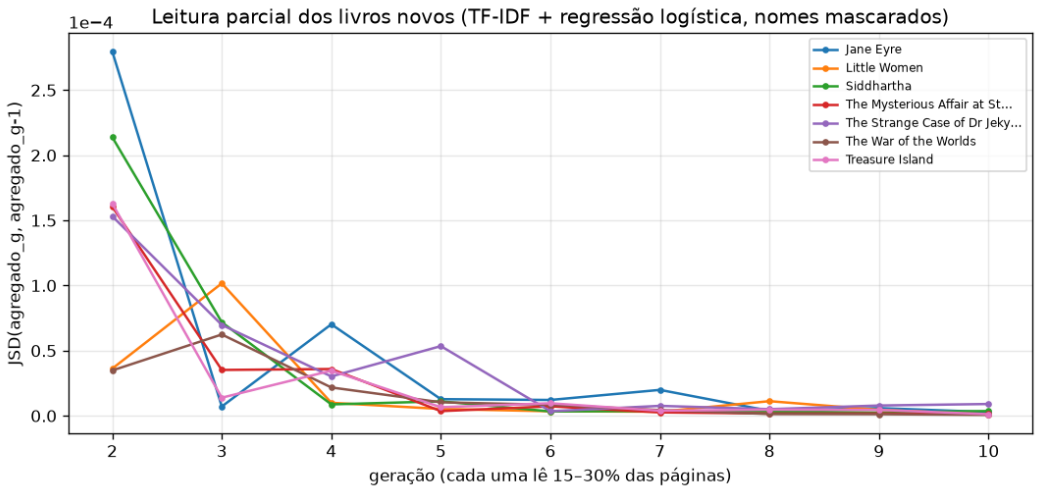


Figura 9 — Leitura parcial dos 7 livros novos (TF-IDF + regressão logística, nomes mascarados): JSD entre agregações consecutivas a cada geração (escala 10^{-4}).

- **Um classificador melhor que o atual.** O pipeline já aceita backends plugáveis (o TF-IDF supervisionado está previsto via `classifier.tfidf.model_path`), então trocar o zero-shot pela regressão logística é uma troca direta, com inferência praticamente instantânea.
- **A premissa central se confirma:** com este classificador, ler 15–30% das páginas por geração dá o mesmo veredito que ler o livro inteiro, e a parada antecipada do pipeline encerraria o laço no mínimo configurado de gerações.
- **Sinal para o agente de RL:** a distância de um segmento aos clusters de sumário e de páginas de rosto pode entrar na recompensa ou servir de filtro prévio.
- **O principal limite a resolver:** um livro por gênero não basta para generalizar (*Siddhartha* falhou em todas as configurações supervisionadas). O próximo passo é ampliar a base para vários livros por gênero, o que a coleta da Etapa 2 já automatiza.

Uso de IA generativa

Fornecedor e modelo: Anthropic, **Claude Opus 5.5** (`claude-opus-5-5`), usado pela ferramenta **Claude Code** (CLI), com acesso ao repositório. O assistente implementou o código de `unidade3/` e as extensões de `src/librarian_ai/` (catálogo, frases e nomes próprios, agregação e classificadores do pipeline), escreveu os testes (97, todos passando), executou os experimentos e redigiu este documento a partir dos resultados medidos.

Prompts utilizados:

- "Bom dia, Claude! Na pasta de Downloads do computador há duas outras pastas. Uma delas chama-se "Modelo", e a outra "Em Andamento". Ainda na pasta de Downloads há um arquivo PDF chamado "PLN - Trabalho Unidade 3". [...] Por gentileza, comece analisando o conteúdo do repositório da pasta "Modelo", depois parta para o conteúdo da "Em Andamento", e por fim, analise o que o PDF acusa que deve ser desenvolvido na "Em Andamento" e realize este desenvolvimento baseando-se intrisecamente na "Modelo". Tome seu tempo. Realize testes unitários para garantir que o projeto da "Em Andamento" atende aos critérios gerais. Complemente a "Em Andamento" de forma limpa e eficiente, garantindo que o modelo PLN funciona e é eficiente."
- "Analise o trabalho, leia os PDFs e gere o PDF do nosso trabalho no padrão do modelo de exemplo. Instale o que for necessário e execute o que for necessário do nosso trabalho para entregar os dados mais precisos e completos possíveis no PDF"